

ⵜⴰⵎⴻⵔⴰⵏⵜ | ⵜⴰⵎⴰⵔⴰⵏⵜ
FACULTÉ DES SCIENCES



كلية العلوم
FACULTY OF SCIENCE

Semlalia

Rapport de projet

MACHINE LEARNING : Prédiction de la qualité du vin à l'aide de techniques de Machine Learning

Réalisée par :

Fatima zahra BAALI

Encadré par :

Prof. Fahd Kalloubi

f.baali3715@uca.ac.ma

Licence ISI - S6

Année universitaire 2026-2027

1. Introduction

L'objectif de ce projet est d'appliquer plusieurs techniques de Machine Learning sur un même dataset afin de résoudre différents types de problèmes : régression, classification et clustering.

Le dataset utilisé est le Wine Quality Dataset (UCI), qui contient plusieurs caractéristiques physico-chimiques du vin rouge. À partir de ces caractéristiques, nous avons étudié différentes approches permettant d'analyser et de prédire la qualité du vin.

Ce projet permet de mettre en pratique les principales notions étudiées en cours de Machine Learning, notamment le prétraitement des données, la visualisation, l'apprentissage supervisé et l'apprentissage non supervisé.

2. Description du Dataset

Le dataset Wine Quality contient 1599 observations et 12 variables.

Les principales caractéristiques sont :

- Fixed Acidity
- Volatile Acidity
- Citric Acid
- Residual Sugar
- Chlorides
- Free Sulfur Dioxide
- Total Sulfur Dioxide
- Density
- pH
- Sulphates
- Alcohol

La variable cible est :

- Quality : note représentant la qualité du vin.

3. Exploration et Analyse des Données

Avant la phase de modélisation, une analyse exploratoire a été réalisée.

Les opérations suivantes ont été effectuées :

- Affichage des premières lignes du dataset.
- Étude de la structure des données.
- Analyse statistique descriptive.
- Vérification des valeurs manquantes.

Afin de mieux comprendre les données, plusieurs visualisations ont été réalisées :

- Histogrammes des variables.
- Matrice de corrélation (Heatmap).

Ces visualisations ont permis d'identifier certaines relations entre les variables et la qualité du vin.

4. Prétraitement des Données

Une nouvelle variable appelée "quality_label" a été créée afin de transformer le problème en classification.

Règle utilisée :

- $\text{quality} \geq 7 \rightarrow \text{Bon vin (1)}$
- $\text{quality} < 7 \rightarrow \text{Vin moyen/faible (0)}$

Aucune valeur manquante n'a été détectée dans le dataset.

Pour les modèles de classification et de clustering, une standardisation des données a également été appliquée à l'aide de StandardScaler.

PARTIE I : RÉGRESSION

5. Régression Linéaire

Dans cette partie, nous avons utilisé le modèle Linear Regression afin de prédire directement la note de qualité du vin.

Les données ont été divisées en :

- 80 % pour l'entraînement
- 20 % pour le test

Les performances du modèle ont été évaluées à l'aide des métriques :

- Mean Squared Error (MSE)
- Coefficient de détermination (R^2)

Résultats

MSE : 0.3900251439639545

R^2 Score : 0.40318034127962254

Ces résultats permettent d'évaluer la capacité du modèle à prédire correctement la qualité du vin.

PARTIE II : CLASSIFICATION

6. Classification

L'objectif est de prédire si un vin est de bonne qualité ou non.

Trois modèles de classification ont été testés :

6.1 Logistic Regression

La régression logistique a été utilisée comme premier modèle de classification.

Accuracy obtenue : 0.865625

6.2 K-Nearest Neighbors (KNN)

Le modèle KNN a été appliqué avec $k = 5$ voisins.

Accuracy obtenue : 0.878125

6.3 Random Forest

Le modèle Random Forest a été utilisé afin d'améliorer les performances de classification.

Accuracy obtenue : 0.90625

Comparaison des modèles

Les résultats obtenus montrent que Random Forest est le modèle le plus performant.

[Insérer ici la capture du graphique de comparaison]

Matrice de confusion

Une matrice de confusion a été générée pour analyser les performances du meilleur modèle.

PARTIE III : CLUSTERING

7. Clustering avec K-Means

Dans cette partie, une méthode d'apprentissage non supervisé a été appliquée.

L'algorithme K-Means a été utilisé afin de regrouper automatiquement les vins en plusieurs clusters selon leurs caractéristiques.

Le nombre de clusters choisi est :

$K = 3$

La visualisation des clusters a permis d'identifier différents groupes de vins présentant des caractéristiques similaires.

8. Discussion

Les différents modèles appliqués ont permis d'étudier le dataset sous plusieurs angles.

La régression a permis de prédire directement la note de qualité.

La classification a permis de distinguer les bons vins des autres.

Le clustering a permis de segmenter automatiquement les vins en groupes homogènes.

Parmi les modèles de classification testés, Random Forest a obtenu les meilleures performances.

9. Conclusion

Dans ce projet, plusieurs techniques de Machine Learning ont été appliquées sur le Wine Quality Dataset.

Les étapes réalisées incluent :

- Exploration des données
- Prétraitement
- Régression Linéaire
- Classification
- Clustering K-Means

Les résultats montrent que les techniques de Machine Learning permettent d'obtenir des prédictions pertinentes concernant la qualité du vin.

Le modèle Random Forest a fourni les meilleures performances en classification, tandis que K-Means a permis d'identifier différents groupes de vins selon leurs caractéristiques.

Ce projet a permis de mettre en pratique les principaux concepts étudiés dans le module de Machine Learning.